Практичне заняття № 2 на тему «Масштабування, нормалізація і стандартизація даних».

Навчальна мета заняття: формування практичних навичок масштабування, нормалізації і стандартизації даних.

Кількість годин – 4 години.

Місце проведення – навчальна аудиторія або комп'ютерний клас.

Навчальні питання:

1. Приведення чисельних даних до єдиної шкали
2. Лінійне масштабування.
3. Стандартизація даних
4. Нелінійне масштабування

Література.

1. Болюбаш Н. М. Інтелектуальний аналіз даних : навч. посіб. / Н. М. Болюбаш. - Миколаїв : Вид-во ЧНУ ім. Петра Могили, 2023. - 320 с.

2. Кононова К. Ю. Машинне навчання: методи та моделі: підручник для бакалаврів, магістрів та докторів філософії спеціальності 051 «Економіка» / К. Ю. Кононова. – Харків: ХНУ імені В. Н. Каразіна, 2020. – 301 с.

3. Charu C. Aggarwal. Data Mining: The Textbook – Cham: Springer Ltd. Publ. Switzerland, 2015. – 734p. URL: https://charuaggarwal.net/Data-Mining.pdf.

4. Основи програмування. Python. Частина 1 [Електронний ресурс]: підручник для студ. спеціальності 122 "Комп'ютерні науки", спеціалізації "Інформаційні технології в біології та медицині" / А. В. Яковенко ; КПІ ім. Ігоря Сікорського. – Електронні текстові данні (1 файл: 1,59 Мбайт). – Київ : КПІ ім. Ігоря Сікорського, 2018. – 195 с.

1. ПІДГОТОВКА ДО ЗАНЯТТЯ.

1.1. Вивчити сутність задачі приведення чисельних даних до єдиної шкали**.**
1.2. Вивчити методи лінійного масштабування даних.
1.3. Вивчити методи нелінійного масштабування даних.
1.4. Вивчити методи стандартизації даних.
1.5. Виконати домашнє завдання і написати звіт.

2. ПЛАН ПРОВЕДЕННЯ ЗАНЯТТЯ.

2.1. Проведення експрес-контролю готовності до заняття:
2.1.1. Перевірка виконання домашнього завдання.
2.1.2. Контрольна робота:
1 варіант: методи лінійного масштабування даних;
2 варіант: методи нелінійного масштабування даних.

2.1.2. Контроль знань теоретичного матеріалу.

2.2. Рішення задач масштабування даних:

2.2.1. Завантажити до свого середовища навчальний файл з датасетом – data1.csv.

2.2.2. Відобразіть гістограму вашого датасету (функція `histplot()`) і оцініть характер розподілу даних по стовпчиках.

2.2.3. Відпрацювати методи лінійного масштабування даних:

1. Мінімаксне масштабування до діапазону [0,1].
2. Мінімаксне масштабування до діапазону [-1,1].
3. Масштабування за максимальним абсолютним значенням.
4. Метод масштабування відносно середнього Mean Scaling.
5. Метод масштабування відносно еталонного значення.
6. Робастне(стійке) масштабування Robust Scaling.

2.2.3. Відпрацювати метод стандартизації даних.

2.2.4. Відпрацювати методи нелінійного масштабування даних:

1. Логарифмічне перетворення (Log Transformation).
2. Квантильне перетворення (Quantile Transformer).
3. Метод Бокса-Кокса (Box-Cox)
4. Метод Йео-Джонсона (Yeo-Johnson)

Порівняйте результати застосування різних методів масштабування і зробіть висновок про найбільш доцільний метод для вашого датасету.

Домашнє завдання:

Завантажити з Kaggle який-небудь датасет (наприклад, «Титанік»). Опрацювати його за наведеною вище методикою.

Можете взяти датасет Іріси Фішера на г-диску або інший, наприклад, популярний датасет Penguins (Пінгвіни) бібліотеки Seaborn або інший з цієї бібліотеки.